

Disciplina de Inteligência Artificial - Professor Munif - Unicesumar 2026

1. Identificação da Equipe

Arthur Antonio Rabelo de Souza - RA: 23003805-2

Felipe Saueressig Mello - RA: 23167656-2

2. Resumo do Projeto

Contextualização e Problema

No mercado financeiro atual, a análise de risco de crédito é crucial para a saúde das instituições bancárias. O problema investigado consiste em prever o risco de inadimplência (**loan default**) de clientes que solicitam empréstimos, além de estimar a taxa de juros ideal baseada no perfil de risco.

Hipótese da Equipe

A hipótese do grupo é de que o modelo **Random Forest** apresentará resultados superiores ao **KNN** em ambas as frentes (classificação e regressão). Isso se deve à capacidade do Random Forest de lidar de forma robusta com dados desbalanceados (comuns em inadimplência) e de criar regras de decisão não lineares complexas sem sofrer tanto com a dispersão multidimensional.

3. Descrição do Dataset

Nome: Credit Risk Dataset (laotse/credit-risk-dataset) obtido via API do Kaggle.

Quantidade de Registros: ~32.000 amostras simuladas de bureau de crédito.

Principais Atributos: Idade, renda anual, tempo de emprego, valor do empréstimo, intenção do empréstimo, nota de risco do banco e histórico prévio de inadimplência.

Variáveis Alvo: `alvo\_inadimplente` (0 para adimplente, 1 para inadimplente) na abordagem de Classificação. `taxa\_juros` (valor numérico contínuo) na abordagem de Regressão.

Tratamento de Dados: Os valores ausentes nas colunas de taxa de juros e tempo de emprego foram preenchidos utilizando a mediana dos dados.

Variáveis categóricas textuais foram convertidas para numéricas através de One-Hot Encoding. Os dados foram divididos na proporção de 80% para treino e 20% para teste.


4. Métodos de IA Utilizados

Parte 1 da Disciplina: K-Nearest Neighbors (KNN) aplicado para Classificação e Regressão (com normalização `StandardScaler`).

Parte 2 da Disciplina: Random Forest (Classifier e Regressor) utilizando conjuntos de árvores de decisão emparelhadas.

5. Avaliação e Comparação dos Modelos

5.1 Frente de Classificação (Prever Inadimplência)




Resultados Estatísticos:

O modelo **Random Forest** obteve melhor desempenho geral, identificando de forma mais assertiva a classe de risco (Inadimplentes), apresentando métricas de precisão e revocação mais equilibradas.

O **KNN** apresentou dificuldades devido ao desbalanceamento natural da base de dados.

5.2 Frente de Regressão (Prever Taxa de Juros)



Resultados Obtidos:

Random Forest Regressor: RMSE de 1.3279% | R^2 Score de 0.8190

KNN Regressão: RMSE de 1.4482% | R^2 Score de 0.7848

6. Conclusão

A análise crítica confirmou a nossa hipótese inicial. O algoritmo Random Forest sobressaiu-se em ambos os cenários de testes. Na classificação, mitigou os impactos do desbalanceamento dos dados. Na regressão, conseguiu explicar 81,90% da variabilidade da taxa de juros (R^2), contra 78,48% do KNN. Conclui-se que arquiteturas baseadas em árvores de decisão em comitê (*ensembles*) são mais recomendadas para cenários complexos de análise de crédito do que abordagens baseadas estritamente em proximidade geométrica (KNN).

7. Como Executar o Projeto

O projeto foi desenvolvido inteiramente em um Notebook do Google Colab. Não é necessário instalar nada em sua máquina local para testá-lo.

Passo a Passo:

1. Abra o arquivo ``TrabalhoFinal_Munif.ipynb`` presente neste repositório.
2. No topo da página (pelo GitHub), você verá um botão escrito **"Open in Colab"** (Abrir no Colab). Clique nele.
3. No menu superior do Colab, clique em **Ambiente de execução -> Executar tudo**.
4. O download da base de dados será feito de forma 100% automática através da API do Kaggle já configurada no código.
5. EXTRA: Caso queira ver o dataset na íntegra, o link é esse:
<https://www.kaggle.com/datasets/laotse/credit-risk-dataset>